

LLM 每日排行榜報告

All LLM Top 30 / 開源 MoE LLM Top 30 / Apple M4 Max 本機採用建議

資料來源: Arena (<https://arena.ai/leaderboard/text>)

資料快照日期: 2026-07-10 / 累積票數: 7,274,904 / 上架模型數: 374

報告產出日期: 2026-07-14

致 Denny Chung

All LLM 排名 Top 30 (1-15)

涵蓋所有廠商含閉源旗艦,依 Arena Elo 分數排序,同系列變體不去重

排名	模型	開發團隊	Arena分數
1	claude-fable-5	Anthropic	1505
2	claude-opus-4-6-thinking	Anthropic	1504
3	claude-opus-4-7-thinking	Anthropic	1503
4	claude-opus-4-6	Anthropic	1498
5	claude-opus-4-7	Anthropic	1494
6	muse-spark-1.1	Meta	1490
7	muse-spark	Meta	1488
8	gpt-5.6-sol-xhigh	OpenAI	1486
9	gemini-3-pro	Google	1486
10	gemini-3.1-pro-preview	Google	1485
11	claude-opus-4-8-thinking	Anthropic	1482
12	gpt-5.5-high	OpenAI	1481
13	gpt-5.4-high	OpenAI	1476
14	gemini-3.5-flash-high	Google	1476
15	gemini-3.5-flash-medium	Google	1476

All LLM 排名 Top 30 (16-30)

涵蓋所有廠商含閉源旗艦,依 Arena Elo 分數排序,同系列變體不去重

排名	模型	開發團隊	Arena分數
16	gpt-5.2-chat-latest-20260210	OpenAI	1476
17	qwen3.7-max-preview	Alibaba	1475
18	claude-opus-4-8	Anthropic	1475
19	grok-4.20-beta1	xAI	1475
20	gpt-5.5	OpenAI	1474
21	grok-4.20-beta-0309-reasoning	xAI	1474
22	gemini-3-flash	Google	1473
23	gpt-5.5-instant	OpenAI	1473
24	claude-opus-4-5-20251101-thinking-32k	Anthropic	1473
25	glm-5.1	Z.ai	1472
26	claude-sonnet-4-6	Anthropic	1472
27	grok-4.20-multi-agent-beta-0309	xAI	1471
28	claude-opus-4-5-20251101	Anthropic	1469
29	grok-4.5	xAI	1469
30	ernie-5.1	Baidu	1468

開源 MoE LLM 排名 Top 30 (1-15)

開放權重(MIT/Apache 2.0/Modified MIT等)且架構為 Mixture-of-Experts

排名	模型	開發團隊	Arena分數
1	glm-5.1	Z.ai	1472
2	mimo-v2.5-pro	Xiaomi	1466
3	glm-5.2 (max)	Z.ai	1465
4	kimi-k2.6	Moonshot	1462
5	deepseek-v4-pro-thinking	DeepSeek	1457
6	glm-5	Z.ai	1457
7	deepseek-v4-pro	DeepSeek	1456
8	kimi-k2.5-thinking	Moonshot	1449
9	minimax-m3	MiniMax	1445
10	glm-4.7	Z.ai	1443
11	qwen3.5-397b-a17b	Alibaba	1442
12	deepseek-v4-flash-thinking	DeepSeek	1439
13	gemma-4-26b-a4b	Google	1438
14	deepseek-v4-flash	DeepSeek	1437
15	mimo-v2.5	Xiaomi	1434

開源 MoE LLM 排名 Top 30 (16-30)

開放權重(MIT/Apache 2.0/Modified MIT等)且架構為 Mixture-of-Experts

排名	模型	開發團隊	Arena分數
16	kimi-k2.5-instant	Moonshot	1432
17	kimi-k2-thinking-turbo	Moonshot	1430
18	glm-4.6	Z.ai	1425
19	deepseek-v3.2	DeepSeek	1425
20	deepseek-v3.2-exp-thinking	DeepSeek	1425
21	qwen3-235b-a22b-instruct-2507	Alibaba	1423
22	nvidia-nemotron-3-ultra-550b-a55b-nvfp4	Nvidia	1423
23	deepseek-v3.2-thinking	DeepSeek	1423
24	deepseek-v3.2-exp	DeepSeek	1423
25	deepseek-r1-0528	DeepSeek	1422
26	kimi-k2-0905-preview	Moonshot	1418
27	deepseek-v3.1-terminus-thinking	DeepSeek	1418
28	deepseek-v3.1	DeepSeek	1418
29	kimi-k2-0711-preview	Moonshot	1418
30	qwen3.5-122b-a10b	Alibaba	1417

Apple M4 Max 本機部署可行性分級說明

分級依據實測/估算之量化後記憶體需求,而非僅依總參數區間粗略判斷

A

36GB就能跑,速度最快

啟用參數 $\leq 4B$ 且總參數小,例如
Gemma 4 26B-A4B、Qwen3-30B-A3B

B

48-64GB可跑,速度尚可

總參數約30-65B且啟用參數偏小,例如
Qwen3.6-35B-A3B、Qwen3-Coder-Next

C

128GB裝得下但很緊繃

實測量化記憶體需求約80-115GB,例如
Qwen3.5-122B-A10B

D

128GB也裝不下,只能用API

實測/估算量化需求超過128GB,例如
DeepSeek V4-Pro、Kimi K2.6、GLM-5系列

MoE LLM 搭配 Apple M4 Max 採用建議 (1-15)

沿用開源MoE Top30名單,分級依 willitrunai 實測或公式估算查證

排名	模型	分數	總參數/啟用參數	分級	備註
1	glm-5.1	1472	744B/40B	D	willitrunai/公開資料估算Q4量化約430GB,遠超128GB,只能用API
2	mimo-v2.5-pro	1466	1.02T/42B	D	總參數逾1T,Q4估算約590GB,只能用API
3	glm-5.2 (max)	1465	753B/40B	D	與GLM-5.1同代架構,Q4估算約435GB,只能用API
4	kimi-k2.6	1462	1T/32B	D	willitrunai實測Q4_K_M約620GB,遠超128GB上限
5	deepseek-v4-pro-thinking	1457	1.6T/49B	D	與deepseek-v4-pro同底座,willitrunai實測約517GB
6	glm-5	1457	745B/44B	D	Q4估算約431GB,只能用API
7	deepseek-v4-pro	1456	1.6T/49B	D	willitrunai實測Q4_K_M約517GB,即使量化仍需多卡伺服器等級記憶體
8	kimi-k2.5-thinking	1449	1T/32B	D	與Kimi K2.6同規模架構,估計約620GB
9	minimax-m3	1445	428B/22-23B	D	willitrunai/社群實測Q4約220-265GB,啟用參數雖僅22B,但推論仍須載入全部專家權重
10	glm-4.7	1443	355B/32B	D	公開資料顯示完整模型部署建議205GB+統一記憶體,遠超128GB
11	qwen3.5-397b-a17b	1442	397B/17B	D	總參數397B,Q4估算約230GB,常被誤認「啟用參數僅17B應該能跑」,實際上仍要裝下全部397B專家權重
12	deepseek-v4-flash-thinking	1439	284B/13B	D	與deepseek-v4-flash同底座,willitrunai實測約180GB,「Flash」之名容易誤導成輕量可本機執行
13	gemma-4-26b-a4b	1438	26B/4B	A	willitrunai實測Q4_K_M僅需約21GB,啟用參數4B、總參數亦小,36GB內即可流暢運行,是今日唯一A級模型
14	deepseek-v4-flash	1437	284B/13B	D	willitrunai實測Q4_K_M約180GB,超過128GB上限
15	mimo-v2.5	1434	310B/15B	D	公開資料估算Q4約180GB,超過128GB

MoE LLM 搭配 Apple M4 Max 採用建議 (16-30)

沿用開源MoE Top30名單,分級依 willitrunai 實測或公式估算查證

排名	模型	分數	總參數/啟用參數	分級	備註
16	kimi-k2.5-instant	1432	1T/32B	D	與Kimi K2家族同規模,估計約620GB
17	kimi-k2-thinking-turbo	1430	1T/32B	D	與Kimi K2家族同規模,估計約620GB
18	glm-4.6	1425	357B/32B	D	公開資料顯示完整部署建議205GB+統一記憶體,遠超128GB
19	deepseek-v3.2	1425	685B/37B	D	公開資料估算INT8需380GB,Q4推估仍需350-400GB
20	deepseek-v3.2-exp-thinking	1425	685B/37B	D	與deepseek-v3.2同底座,估算約350-400GB
21	qwen3-235b-a22b-instruct-2507	1423	235B/22B	D	★常見誤解代表:willitrunai實測Q4約132GB,僅略超128GB上限,常被誤以為128GB機型裝得下,實際仍裝不下,需更激進量化才勉強塞入且會犧牲品質
22	nvidia-nemotron-3-ultra-550b-a55b-nvfp4	1423	550B/55B	D	雖已採NVFP4(4bit)原生量化格式,550B總參數仍估算需約290GB,遠超128GB
23	deepseek-v3.2-thinking	1423	685B/37B	D	與deepseek-v3.2同底座,估算約350-400GB
24	deepseek-v3.2-exp	1423	685B/37B	D	與deepseek-v3.2同底座,估算約350-400GB
25	deepseek-r1-0528	1422	671B/37B	D	公開資料估算Q4約400-404GB,遠超128GB
26	kimi-k2-0905-preview	1418	1T/32B	D	Kimi K2舊版預覽,與K2家族同規模,估計約620GB
27	deepseek-v3.1-terminus-thinking	1418	671B/37B	D	與DeepSeek V3.1同底座,估算約400GB
28	deepseek-v3.1	1418	671B/37B	D	估算Q4約400GB,遠超128GB
29	kimi-k2-0711-preview	1418	1T/32B	D	Kimi K2初版,與K2家族同規模,估計約620GB
30	qwen3.5-122b-a10b	1417	122B/10B	C	willitrunai實測Q4_K_M約74-78GB,128GB統一記憶體內可跑,是Top30中除gemma-4-26b-a4b外唯一能塞入128GB的模型,但仍偏向中高階配置

結論與建議

依當日 Arena 排名與 M4 Max 128GB 部署查證結果

日常本機首選

gemma-4-26b-a4b

Arena分數 1438 / 分級 A

今日Top30開源MoE中唯一A級模型,willitrunai實測僅需約21GB,速度快、隨開即用,為日常本機首選

品質優先(128GB機型)

qwen3.5-122b-a10b

Arena分數 1417 / 分級 C

128GB機型上能塞入(約74-78GB)的模型中總參數規模最大(122B),雖Arena分數略低於gemma-4-26b-a4b,但推理容量更大,適合追求品質的本機使用場景

旗艦模型現況

Top30中有 28/30 款為 D級(裝不下)

Arena分數 / 分級

Qwen3-235B-A22B-Instruct-2507:常被誤認128GB機型裝得下,willitrunai實測Q4量化約132GB,實際上仍超出128GB上限

DeepSeek V4 Flash(284B總參數):模型名稱帶「Flash」易被誤認為輕量可本機執行,willitrunai實測仍需約180GB

MiniMax M3(428B總參數/約22B啟用):啟用參數不大不代表模型檔案小,推論時仍需把全部專家權重載入記憶體,Q4量化仍需220-265GB

與前一日報告比較: Arena榜單快照與昨日(2026-07-13報告)完全相同,仍為2026-07-10版本(累積票數7,274,904、上架模型374款皆未變動),故Top30 Overall、Top30開源MoE、M4 Max分級與結論均無升降榜變化。已重新抓取並逐筆核對排名1-135確認無誤,非沿用推測。