

LLM 每日排行榜報告

All LLM Top 30 / 開源 MoE LLM Top 30 / Apple M4 Max 本機採用建議

資料來源: Arena (<https://arena.ai/leaderboard/text>)

資料快照日期: 2026-07-15 / 累積票數: 7,308,667 / 上架模型數: 374

報告產出日期: 2026-07-15

致 Denny Chung

All LLM 排名 Top 30 (1-15)

涵蓋所有廠商含閉源旗艦,依 Arena Elo 分數排序,同系列變體不去重

排名	模型	開發團隊	Arena分數
1	claude-fable-5	Anthropic	1508
2	claude-opus-4-6-thinking	Anthropic	1504
3	claude-opus-4-7-thinking	Anthropic	1503
4	claude-opus-4-6	Anthropic	1498
5	claude-opus-4-7	Anthropic	1494
6	muse-spark-1.1	Meta	1491
7	muse-spark	Meta	1488
8	gemini-3.1-pro-preview	Google	1486
9	gemini-3-pro	Google	1486
10	gpt-5.6-sol-xhigh	OpenAI	1484
11	claude-opus-4-8-thinking	Anthropic	1483
12	gpt-5.5-high	OpenAI	1482
13	gpt-5.4-high	OpenAI	1477
14	gemini-3.5-flash-high	Google	1476
15	gpt-5.2-chat-latest-20260210	OpenAI	1476

All LLM 排名 Top 30 (16-30)

涵蓋所有廠商含閉源旗艦,依 Arena Elo 分數排序,同系列變體不去重

排名	模型	開發團隊	Arena分數
16	qwen3.7-max-preview	Alibaba	1475
17	gemini-3.5-flash-medium	Google	1475
18	claude-opus-4-8	Anthropic	1475
19	grok-4.20-beta1	SpaceXAI	1474
20	gpt-5.5	OpenAI	1474
21	grok-4.20-beta-0309-reasoning	SpaceXAI	1474
22	gemini-3-flash	Google	1473
23	gpt-5.5-instant	OpenAI	1473
24	claude-opus-4-5-20251101-thinking-32k	Anthropic	1473
25	glm-5.1	Z.ai	1472
26	claude-sonnet-4-6	Anthropic	1472
27	grok-4.20-multi-agent-beta-0309	SpaceXAI	1471
28	claude-opus-4-5-20251101	Anthropic	1469
29	ernie-5.1	Baidu	1468
30	grok-4.1-thinking	SpaceXAI	1466

開源 MoE LLM 排名 Top 30 (1-15)

開放權重(MIT/Apache 2.0/Modified MIT等)且架構為 Mixture-of-Experts

排名	模型	開發團隊	Arena分數
1	glm-5.1	Z.ai	1472
2	mimo-v2.5-pro	Xiaomi	1466
3	glm-5.2 (max)	Z.ai	1465
4	kimi-k2.6	Moonshot	1462
5	deepseek-v4-pro-thinking	DeepSeek	1457
6	deepseek-v4-pro	DeepSeek	1457
7	glm-5	Z.ai	1456
8	kimi-k2.5-thinking	Moonshot	1449
9	minimax-m3	MiniMax	1445
10	glm-4.7	Z.ai	1442
11	qwen3.5-397b-a17b	Alibaba	1442
12	deepseek-v4-flash-thinking	DeepSeek	1438
13	gemma-4-26b-a4b	Google	1438
14	deepseek-v4-flash	DeepSeek	1438
15	longcat-flash-chat-2602-exp	Meituan	1436

開源 MoE LLM 排名 Top 30 (16-30)

開放權重(MIT/Apache 2.0/Modified MIT等)且架構為 Mixture-of-Experts

排名	模型	開發團隊	Arena分數
16	mimo-v2.5	Xiaomi	1433
17	kimi-k2.5-instant	Moonshot	1432
18	kimi-k2-thinking-turbo	Moonshot	1430
19	glm-4.6	Z.ai	1425
20	deepseek-v3.2	DeepSeek	1425
21	deepseek-v3.2-exp-thinking	DeepSeek	1425
22	qwen3-235b-a22b-instruct-2507	Alibaba	1423
23	deepseek-v3.2-thinking	DeepSeek	1423
24	deepseek-v3.2-exp	DeepSeek	1423
25	nvidia-nemotron-3-ultra-550b-a55b-nvfp4	Nvidia	1423
26	deepseek-r1-0528	DeepSeek	1422
27	kimi-k2-0905-preview	Moonshot	1418
28	deepseek-v3.1-terminus-thinking	DeepSeek	1418
29	deepseek-v3.1	DeepSeek	1418
30	kimi-k2-0711-preview	Moonshot	1417

Apple M4 Max 本機部署可行性分級說明

分級依據實測/估算之量化後記憶體需求,而非僅依總參數區間粗略判斷

A

36GB就能跑,速度最快

啟用參數 $\leq 4B$ 且總參數小,例如
Gemma 4 26B-A4B、Qwen3-30B-A3B

B

48-64GB可跑,速度尚可

總參數約30-65B且啟用參數偏小,例如
Qwen3.6-35B-A3B、Qwen3-Coder-Next

C

128GB裝得下但很緊繃

實測量化記憶體需求約80-115GB,例如
Qwen3.5-122B-A10B

D

128GB也裝不下,只能用API

實測/估算量化需求超過128GB,例如
DeepSeek V4-Pro、Kimi K2.6、GLM-5系列

MoE LLM 搭配 Apple M4 Max 採用建議 (1-15)

沿用開源MoE Top30名單,分級依 willitrunai 實測或公式估算查證

排名	模型	分數	總參數/啟用參數	分級	備註
1	glm-5.1	1472	754B/40B	D	willitrunai實測Q4_K_M約482GB,遠超128GB,只能用API
2	mimo-v2.5-pro	1466	1.02T/42B	D	willitrunai/Nodepedia實測Q4_K_M約675GB,遠超128GB
3	glm-5.2 (max)	1465	744B/40B	D	與GLM-5同代架構,Q4_K_M約476GB,只能用API
4	kimi-k2.6	1462	1T/32B	D	willitrunai實測Q4_K_M約620GB,遠超128GB上限
5	deepseek-v4-pro-thinking	1457	1.6T/49B	D	原生FP4+FP8混合精度已需約800GB,經Q4_K_M再量化willitrunai實測約517GB,仍遠超128GB
6	deepseek-v4-pro	1457	1.6T/49B	D	willitrunai實測Q4_K_M約517GB,即使原生已採FP4+FP8混合精度仍需多卡伺服器等級記憶體
7	glm-5	1456	744B/40B	D	willitrunai實測Q4_K_M約476GB,只能用API
8	kimi-k2.5-thinking	1449	1T/32B	D	與Kimi K2.6同規模架構,估計約620GB
9	minimax-m3	1445	428B/22-23B	D	willitrunai/社群實測Q4約220-265GB,啟用參數雖僅22-23B,但推論仍須載入全部專家權重
10	glm-4.7	1442	355B/32B	D	willitrunai/Unsloth資料顯示完整模型約400GB,即使動態量化仍約134-230GB,遠超128GB
11	qwen3.5-397b-a17b	1442	397B/17B	D	總參數397B,Q4估算約230-260GB,常被誤認「啟用參數僅17B應該能跑」,實際上仍要裝下全部397B專家權重
12	deepseek-v4-flash-thinking	1438	284B/13B	C	★今日更正發現:因採用原生FP4+FP8混合精度(MoE專家層原生FP4),官方模型卡與willitrunai/Nodepedia資料顯示Q4_K_M僅需約95-104GB,128GB機型可跑,是Top30中少數能在128GB內運行的中大型模型
13	gemma-4-26b-a4b	1438	26B/4B	A	willitrunai實測Q4_K_M僅需約20.8GB,啟用參數4B、總參數亦小,36GB內即可流暢運行,是今日唯一A級模型
14	deepseek-v4-flash	1438	284B/13B	C	與deepseek-v4-flash-thinking同底座,官方模型卡/willitrunai顯示Q4_K_M約95-104GB,128GB機型可跑但偏緊繃
15	longcat-flash-chat-2602-exp	1436	1.6T/33-56B(平均48B)	D	今日新納入Top30開源MoE名單(LongCat-2.0系列,MIT授權,經查證確認符合開源+MoE資格);willitrunai無此模型資料,參考Spheron估算INT4約968GB,遠超128GB

MoE LLM 搭配 Apple M4 Max 採用建議 (16-30)

沿用開源MoE Top30名單,分級依 willitrunai 實測或公式估算查證

排名	模型	分數	總參數/啟用參數	分級	備註
16	mimo-v2.5	1433	310.8B/15B	D	與mimo-v2.5-pro同架構,依比例推估Q4約180-205GB(willitrunai無此版本明確數據),超過128GB
17	kimi-k2.5-instant	1432	1T/32B	D	與Kimi K2家族同規模,估計約620GB
18	kimi-k2-thinking-turbo	1430	1T/32B	D	與Kimi K2家族同規模,估計約620GB
19	glm-4.6	1425	357B/32B	D	與GLM-4.7同級,估算約200-230GB,遠超128GB
20	deepseek-v3.2	1425	685B/37B	D	公開資料估算Q4約350-400GB
21	deepseek-v3.2-exp-thinking	1425	685B/37B	D	與deepseek-v3.2同底座,估算約350-400GB
22	qwen3-235b-a22b-instruct-2507	1423	235B/22B	D	★常見誤解代表:willitrunai實測Q4約132GB,僅略超128GB上限,常被誤以為128GB機型裝得下,實際仍裝不下
23	deepseek-v3.2-thinking	1423	685B/37B	D	與deepseek-v3.2同底座,估算約350-400GB
24	deepseek-v3.2-exp	1423	685B/37B	D	與deepseek-v3.2同底座,估算約350-400GB
25	nvidia-nemotron-3-ultra-550b-a55b-nvfp4	1423	550B/55B	D	雖採NVFP4原生量化,550B總參數估算仍需約275GB,進一步INT4量化約183GB,仍超128GB
26	deepseek-r1-0528	1422	671B/37B	D	公開資料估算Q4約400-404GB,遠超128GB
27	kimi-k2-0905-preview	1418	1T/32B	D	Kimi K2舊版預覽,與K2家族同規模,估計約620GB
28	deepseek-v3.1-terminus-thinking	1418	671B/37B	D	與DeepSeek V3.1同底座,估算約400GB
29	deepseek-v3.1	1418	671B/37B	D	估算Q4約400GB,遠超128GB
30	kimi-k2-0711-preview	1417	1T/32B	D	Kimi K2初版,與K2家族同規模,估計約620GB

結論與建議

依當日 Arena 排名與 M4 Max 128GB 部署查證結果

日常本機首選

gemma-4-26b-a4b

Arena分數 1438 / 分級 A

今日Top30開源MoE中唯一A級模型,willitrunai實測僅需約20.8GB,速度快、隨開即用,為日常本機首選

品質優先(128GB機型)

deepseek-v4-flash-thinking

Arena分數 1438 / 分級 C

今日重大更正發現:因原生FP4+FP8混合精度大幅壓縮權重,Q4_K_M僅需約95-104GB即可在128GB機型上運行;總參數規模(284B)遠大於gemma-4-26b-a4b,同分但推理容量更大,適合追求品質的本機使用場景

旗艦模型現況

Top30中有 27/30 款為 D級(裝不下)

Arena分數 / 分級

DeepSeek V4 Flash / V4 Flash-Thinking(反向誤解修正):表面284B總參數容易被誤判為裝不下,但因採用原生FP4+FP8混合精度,官方模型卡與willitrunai資料顯示Q4_K_M僅需95-104GB,實際上是Top30中少數能在128GB內運行的機型

Qwen3-235B-A22B-Instruct-2507:常被誤認128GB機型裝得下,willitrunai實測Q4量化約132GB,僅略超128GB上限,實際仍裝不下

GLM-5系列(744-754B總參數):MoE架構常被誤認對本機部署友善,willitrunai實測仍需476-482GB,只能透過API使用

與前一日報告比較: 與昨日(2026-07-14報告,快照日期2026-07-10)相比,本次為重新即時抓取的最新快照(2026-07-15):累積票數由7,274,904增至7,308,667(+33,763),上架模型數維持374款不變。Top30 Overall排名結構大致穩定(前10名相同,僅grok系列開發商標籤因xAI已於2026-07-06完成併入SpaceX並更名SpaceXAI而更新,Grok品牌本身未變)。Top30開源MoE名單本次因擴大搜尋範圍並逐一查證授權與架構,新確認longcat-flash-chat-2602-exp(Meituan LongCat-2.0系列,MIT授權,MoE)符合資格並納入榜單,導致原本第30名的qwen3.5-122b-a10b(昨日quality_pick)被擠出Top30。另外,本次重新查證DeepSeek V4 Flash/V4 Flash-Thinking的官方模型卡與willitrunai資料,發現其採用原生FP4+FP8混合精度,Q4_K_M實際僅需95-104GB(而非先前估計的約180GB),評級由D級上修為C級,並取代qwen3.5-122b-a10b成為新的quality_pick。