

LLM-Daily-Survey 2026/07/16

LLM 每日排行榜報告

All LLM Top 30 / 開源 MoE LLM Top 30 / Apple M4 Max 本機採用建議 / MacBook Air 16GB Agentic 部署評估

資料來源: Arena (<https://arena.ai/leaderboard/text>)

資料快照日期: 2026-07-16 / 累積票數: 7,308,667 / 上架模型數: 374

報告產出日期: 2026-07-16

致 Denny Chung

All LLM 排名 Top 30 (1-15)

涵蓋所有廠商含閉源旗艦,依 Arena Elo 分數排序,同系列變體不去重

排名	模型	開發團隊	Arena分數
1	claude-fable-5	Anthropic	1508
2	claude-opus-4-6-thinking	Anthropic	1504
3	claude-opus-4-7-thinking	Anthropic	1503
4	claude-opus-4-6	Anthropic	1498
5	claude-opus-4-7	Anthropic	1494
6	muse-spark-1.1	Meta	1491
7	muse-spark	Meta	1488
8	gemini-3.1-pro-preview	Google	1486
9	gemini-3-pro	Google	1486
10	gpt-5.6-sol-xhigh	OpenAI	1484
11	claude-opus-4-8-thinking	Anthropic	1483
12	gpt-5.5-high	OpenAI	1482
13	gpt-5.4-high	OpenAI	1477
14	gemini-3.5-flash-high	Google	1476
15	gpt-5.2-chat-latest-20260210	OpenAI	1476

All LLM 排名 Top 30 (16-30)

涵蓋所有廠商含閉源旗艦,依 Arena Elo 分數排序,同系列變體不去重

排名	模型	開發團隊	Arena分數
16	qwen3.7-max-preview	Alibaba	1475
17	gemini-3.5-flash-medium	Google	1475
18	claude-opus-4-8	Anthropic	1475
19	grok-4.20-beta1	SpaceXAI	1474
20	gpt-5.5	OpenAI	1474
21	grok-4.20-beta-0309-reasoning	SpaceXAI	1474
22	gemini-3-flash	Google	1473
23	gpt-5.5-instant	OpenAI	1473
24	claude-opus-4-5-20251101-thinking-32k	Anthropic	1473
25	glm-5.1	Z.ai	1472
26	claude-sonnet-4-6	Anthropic	1472
27	grok-4.20-multi-agent-beta-0309	SpaceXAI	1471
28	claude-opus-4-5-20251101	Anthropic	1469
29	ernie-5.1	Baidu	1468
30	grok-4.1-thinking	SpaceXAI	1466

開源 MoE LLM 排名 Top 30 (1-15)

開放權重(MIT/Apache 2.0/Modified MIT等)且架構為 Mixture-of-Experts

排名	模型	開發團隊	Arena分數
1	glm-5.1	Z.ai	1472
2	mimo-v2.5-pro	Xiaomi	1466
3	glm-5.2 (max)	Z.ai	1465
4	kimi-k2.6	Moonshot	1462
5	deepseek-v4-pro-thinking	DeepSeek	1457
6	deepseek-v4-pro	DeepSeek	1457
7	glm-5	Z.ai	1456
8	kimi-k2.5-thinking	Moonshot	1449
9	minimax-m3	MiniMax	1445
10	glm-4.7	Z.ai	1442
11	qwen3.5-397b-a17b	Alibaba	1442
12	deepseek-v4-flash-thinking	DeepSeek	1438
13	gemma-4-26b-a4b	Google	1438
14	deepseek-v4-flash	DeepSeek	1438
15	longcat-flash-chat-2602-exp	Meituan	1436

開源 MoE LLM 排名 Top 30 (16-30)

開放權重(MIT/Apache 2.0/Modified MIT等)且架構為 Mixture-of-Experts

排名	模型	開發團隊	Arena分數
16	mimo-v2.5	Xiaomi	1433
17	kimi-k2.5-instant	Moonshot	1432
18	kimi-k2-thinking-turbo	Moonshot	1430
19	glm-4.6	Z.ai	1425
20	deepseek-v3.2	DeepSeek	1425
21	deepseek-v3.2-exp-thinking	DeepSeek	1425
22	qwen3-235b-a22b-instruct-2507	Alibaba	1423
23	deepseek-v3.2-thinking	DeepSeek	1423
24	deepseek-v3.2-exp	DeepSeek	1423
25	nvidia-nemotron-3-ultra-550b-a55b-nvfp4	Nvidia	1423
26	deepseek-r1-0528	DeepSeek	1422
27	kimi-k2-0905-preview	Moonshot	1418
28	deepseek-v3.1-terminus-thinking	DeepSeek	1418
29	deepseek-v3.1	DeepSeek	1418
30	kimi-k2-0711-preview	Moonshot	1417

Apple M4 Max 本機部署可行性分級說明

分級依據實測/估算之量化後記憶體需求,而非僅依總參數區間粗略判斷

A

36GB就能跑,速度最快

啟用參數 $\leq 4B$ 且總參數小,例如
Gemma 4 26B-A4B、Qwen3-30B-A3B

B

48-64GB可跑,速度尚可

總參數約30-65B且啟用參數偏小,例如
Qwen3.6-35B-A3B、Qwen3-Coder-Next

C

128GB裝得下但很緊繃

實測量化記憶體需求約80-115GB,例如
Qwen3.5-122B-A10B

D

128GB也裝不下,只能用API

實測/估算量化需求超過128GB,例如
DeepSeek V4-Pro、Kimi K2.6、GLM-5系列

MoE LLM 搭配 Apple M4 Max 採用建議 (1-15)

沿用開源MoE Top30名單,分級依 willitrunai 實測或公式估算查證

排名	模型	分數	總參數/啟用參數	分級	備註
1	glm-5.1	1472	754B/40B	D	willitrunai實測Q4_K_M約482GB,遠超128GB,只能用API
2	mimo-v2.5-pro	1466	1.02T/42B	D	willitrunai/Nodepedia實測Q4_K_M約675GB,遠超128GB
3	glm-5.2 (max)	1465	744B/40B	D	與GLM-5同代架構,Q4_K_M約476GB,只能用API
4	kimi-k2.6	1462	1T/32B	D	willitrunai實測Q4_K_M約620GB,遠超128GB上限
5	deepseek-v4-pro-thinking	1457	1.6T/49B	D	原生FP4+FP8混合精度已需約800GB,經Q4_K_M再量化willitrunai實測約517GB,仍遠超128GB
6	deepseek-v4-pro	1457	1.6T/49B	D	willitrunai實測Q4_K_M約517GB,即使原生已採FP4+FP8混合精度仍需多卡伺服器等級記憶體
7	glm-5	1456	744B/40B	D	willitrunai實測Q4_K_M約476GB,只能用API
8	kimi-k2.5-thinking	1449	1T/32B	D	與Kimi K2.6同規模架構,估計約620GB
9	minimax-m3	1445	428B/22-23B	D	willitrunai/社群實測Q4約220-265GB,啟用參數雖僅22-23B,但推論仍須載入全部專家權重
10	glm-4.7	1442	355B/32B	D	willitrunai/Unsloth資料顯示完整模型約400GB,即使動態量化仍約134-230GB,遠超128GB
11	qwen3.5-397b-a17b	1442	397B/17B	D	總參數397B,Q4估算約230-260GB,常被誤認「啟用參數僅17B應該能跑」,實際上仍要裝下全部397B專家權重
12	deepseek-v4-flash-thinking	1438	284B/13B	C	採原生FP4+FP8混合精度(MoE專家層原生FP4),官方模型卡與willitrunai/Nodepedia資料顯示Q4_K_M僅需約95-104GB,128GB機型可跑,是Top30中少數能在128GB內運行的中大型模型(沿用07-15查證結果,今日榜單未變動)
13	gemma-4-26b-a4b	1438	26B/4B	A	willitrunai實測標準Q4_K_M約20.8GB,啟用參數4B、總參數亦小,36GB內即可流暢運行,是今日唯一A級模型
14	deepseek-v4-flash	1438	284B/13B	C	與deepseek-v4-flash-thinking同底座,官方模型卡/willitrunai顯示Q4_K_M約95-104GB,128GB機型可跑但偏緊繃
15	longcat-flash-chat-2602-exp	1436	1.6T/33-56B(平均48B)	D	LongCat-2.0系列,MIT授權,經查證確認符合開源+MoE資格;willitrunai無此模型資料,參考Spheron估算INT4約968GB,遠超128GB

MoE LLM 搭配 Apple M4 Max 採用建議 (16-30)

沿用開源MoE Top30名單,分級依 willitrunai 實測或公式估算查證

排名	模型	分數	總參數/啟用參數	分級	備註
16	mimo-v2.5	1433	310.8B/15B	D	與mimo-v2.5-pro同架構,依比例推估Q4約180-205GB(willitrunai無此版本明確數據),超過128GB
17	kimi-k2.5-instant	1432	1T/32B	D	與Kimi K2家族同規模,估計約620GB
18	kimi-k2-thinking-turbo	1430	1T/32B	D	與Kimi K2家族同規模,估計約620GB
19	glm-4.6	1425	357B/32B	D	與GLM-4.7同級,估算約200-230GB,遠超128GB
20	deepseek-v3.2	1425	685B/37B	D	公開資料估算Q4約350-400GB
21	deepseek-v3.2-exp-thinking	1425	685B/37B	D	與deepseek-v3.2同底座,估算約350-400GB
22	qwen3-235b-a22b-instruct-2507	1423	235B/22B	D	★常見誤解代表:willitrunai實測Q4約132GB,僅略超128GB上限,常被誤以為128GB機型裝得下,實際仍裝不下
23	deepseek-v3.2-thinking	1423	685B/37B	D	與deepseek-v3.2同底座,估算約350-400GB
24	deepseek-v3.2-exp	1423	685B/37B	D	與deepseek-v3.2同底座,估算約350-400GB
25	nvidia-nemotron-3-ultra-550b-a55b-nvfp4	1423	550B/55B	D	雖採NVFP4原生量化,550B總參數估算仍需約275GB,進一步INT4量化約183GB,仍超128GB
26	deepseek-r1-0528	1422	671B/37B	D	公開資料估算Q4約400-404GB,遠超128GB
27	kimi-k2-0905-preview	1418	1T/32B	D	Kimi K2舊版預覽,與K2家族同規模,估計約620GB
28	deepseek-v3.1-terminus-thinking	1418	671B/37B	D	與DeepSeek V3.1同底座,估算約400GB
29	deepseek-v3.1	1418	671B/37B	D	估算Q4約400GB,遠超128GB
30	kimi-k2-0711-preview	1417	1T/32B	D	Kimi K2初版,與K2家族同規模,估計約620GB

MacBook Air 16GB 地端 Agentic AI 部署評估

16GB統一記憶體扣掉macOS系統保留,實際可用約8-10GB;Agentic工作負載KV cache持續成長,權重建議壓在6-8GB內;Air無風扇,持續agent迴圈會熱降頻

模型	開發團隊	總參數/啟用	Q4記憶體	判定	備註
LFM2.5-8B-A1B	Liquid AI	8.3B/1.5B	Q4_K_M ~6GB(官方)	可跑	128K context,原生tool calling+reasoning;授權為LFM 1.0開放權重(非MIT/Apache),商用前需確認條款
ERNIE-4.5-21B-A3B	Baidu	21B/3B	Q4約12-13GB(估算)	緊繃	Apache 2.0;無willitrunai實測,agentic長context不建議
qwen3-30b-a3b	Alibaba	30B/3B	Q4約16.8-21.9GB	裝不下	willitrunai建議32GB以上機型
qwen3.5-35b-a3b	Alibaba	35B/3B	Q4_K_M約21.4GB	裝不下	willitrunai實測,需32GB以上機型
gemma-4-26b-a4b	Google	26B/4B	標準Q4_K_M約20.8GB;新版QAT 4-bit checkpoint約15GB(2026-07 QAT release,今日spot-check發現)	裝不下	QAT版本已比標準量化省約5-6GB,但仍超過16GB Air約11GB上限的agentic預算(256K context下還需額外KV cache),verdict維持裝不下
gpt-oss-20b	OpenAI	21B/3.6B	Q4_K_M權重約12GB,含KV cache估計12-22.5GB(來源分歧,willitrunai/Spheron/社群數據不一)	裝不下	今日spot-check新發現的候選(Apache 2.0);即使取估計區間下緣12GB,仍超過16GB Air的11GB門檻,agentic長context會更緊繃

Agentic MoE 首選

LFM2.5-8B-A1B

8.3B/1.5B / Q4_K_M ~6GB

16GB Air上唯一從容可跑的MoE:剩3-4GB給KV cache;128K context、原生tool calling、內建reasoning;啟用1.5B在無風扇Air上速度快、發熱低。今日spot-check的Gemma-4 QAT與gpt-oss-20b均未能取代此首選

Dense 替代方案

Qwen3.5-9B

9B dense / Q4約7GB

Apache 2.0;2026年多篇16GB Mac評測評為agentic/tool calling最強全能選擇,品質上限比LFM2.5高,適合單次重推理任務

結論與建議

依當日 Arena 排名與 M4 Max 128GB 部署查證結果

日常本機首選

gemma-4-26b-a4b

Arena分數 1438 / 分級 A

今日Top30開源MoE中唯一A級模型,willitrunai實測僅需約20.8GB,速度快、隨開即用,為日常本機首選(M4 Max適用;16GB Air仍裝不下,見air16_eval)

品質優先(128GB機型)

deepseek-v4-flash-thinking

Arena分數 1438 / 分級 C

因原生FP4+FP8混合精度大幅壓縮權重,Q4_K_M僅需約95-104GB即可在128GB機型上運行;總參數規模(284B)遠大於gemma-4-26b-a4b,同分但推理容量更大,適合追求品質的本機使用場景

旗艦模型現況

Top30中有 27/30 款為 D級(裝不下)

Arena分數 / 分級

DeepSeek V4 Flash / V4 Flash-Thinking(反向誤解修正):表面284B總參數容易被誤判為裝不下,但因採用原生FP4+FP8混合精度,官方模型卡與willitrunai資料顯示Q4_K_M僅需95-104GB,實際上是Top30中少數能在128GB內運行的機型

Qwen3-235B-A22B-Instruct-2507:常被誤認128GB機型裝得下,willitrunai實測Q4量化約132GB,僅略超128GB上限,實際仍裝不下

GLM-5系列(744-754B總參數):MoE架構常被誤認對本機部署友善,willitrunai實測仍需476-482GB,只能透過API使用

與前一日報告比較: 今日(2026-07-16)重新抓取arena.ai/leaderboard/text,但頁面本身顯示的快照時間戳記仍為「Jul 13, 2026」,經查閱官方changelog確認自07-13起無新資料更新(累積票數同為7,308,667、上架模型數同為374)——與昨日(2026-07-15)報告使用的是同一份底層快照,因此Top30 Overall、Top30開源MoE榜單、分數、排名皆與昨日完全相同,並非本次抓取遺漏或連線失敗,而是上游網站尚未刷新(誠實揭露,非編造)。M4 Max記憶體分級沿用07-15查證結果(模型清單未變動,無新查證需求)。MacBook Air 16GB部分依runbook每日spot-check要求執行了一次WebSearch,新發現兩項候選:(1)Google Gemma-4-26B-A4B新推出QAT量化版,4-bit checkpoint降至約15GB,優於先前標準Q4_K_M實測的20.8GB,但仍超過16GB Air約11GB的agentic預算上限,verdict維持「裝不下」;(2)OpenAI gpt-oss-20b(21B/3.6B啟用,Apache 2.0),Q4_K_M權重約12GB(含KV cache來源分歧、估計12-22.5GB),同樣超過11GB門檻,verdict為「裝不下」。兩項新發現均未動搖現有首選LFM2.5-8B-A1B(MoE)與Qwen3.5-9B(dense替代)。