

LLM-Daily-Survey 2026/07/22

LLM 每日排行榜報告

All LLM Top 30 / 開源 MoE LLM Top 30 / Apple M4 Max 本機採用建議 / MacBook Air 16GB Agentic 部署評估

資料來源: Arena (<https://arena.ai/leaderboard/text>)

資料快照日期: 2026-07-22 / 累積票數: 7,430,560 / 上架模型數: 378

報告產出日期: 2026-07-22

致 Denny Chung

All LLM 排名 Top 30 (1-15)

涵蓋所有廠商含閉源旗艦,依 Arena Elo 分數排序,同系列變體不去重

排名	模型	開發團隊	Arena分數
1	claude-fable-5	Anthropic	1507
2	claude-opus-4-6-thinking	Anthropic	1505
3	claude-opus-4-7-thinking	Anthropic	1502
4	claude-opus-4-6	Anthropic	1498
5	muse-spark-1.1	Meta	1495
6	claude-opus-4-7	Anthropic	1494
7	muse-spark	Meta	1488
8	gemini-3.1-pro-preview	Google	1486
9	gemini-3-pro	Google	1486
10	kimi-k3	Moonshot	1486
11	gpt-5.6-sol-xhigh	OpenAI	1485
12	gemini-3.6-flash	Google	1485
13	claude-opus-4-8-thinking	Anthropic	1484
14	gpt-5.5-high	OpenAI	1482
15	gpt-5.4-high	OpenAI	1478

All LLM 排名 Top 30 (16-30)

涵蓋所有廠商含閉源旗艦,依 Arena Elo 分數排序,同系列變體不去重

排名	模型	開發團隊	Arena分數
16	gpt-5.5	OpenAI	1476
17	gemini-3.5-flash-high	Google	1476
18	gpt-5.2-chat-latest-20260210	OpenAI	1476
19	qwen3.7-max-preview	Alibaba	1475
20	grok-4.20-beta1	xAI	1474
21	gemini-3.5-flash-medium	Google	1474
22	claude-opus-4-8	Anthropic	1473
23	gpt-5.5-instant	OpenAI	1473
24	grok-4.20-beta-0309-reasoning	xAI	1473
25	gemini-3-flash	Google	1473
26	claude-opus-4-5-20251101-thinking-32k	Anthropic	1473
27	claude-sonnet-4-6	Anthropic	1473
28	grok-4.20-multi-agent-beta-0309	xAI	1471
29	glm-5.1	Z.ai	1470
30	glm-5.2 (max)	Z.ai	1469

開源 MoE LLM 排名 Top 30 (1-15)

開放權重(MIT/Apache 2.0/Modified MIT等)且架構為 Mixture-of-Experts

排名	模型	開發團隊	Arena分數
1	glm-5.1	Z.ai	1470
2	glm-5.2 (max)	Z.ai	1469
3	mimo-v2.5-pro	Xiaomi	1467
4	kimi-k2.6	Moonshot	1461
5	glm-5	Z.ai	1457
6	deepseek-v4-pro	DeepSeek	1457
7	deepseek-v4-pro-thinking	DeepSeek	1455
8	kimi-k2.5-thinking	Moonshot	1450
9	inkling	Thinking Machines Lab	1445
10	minimax-m3	MiniMax	1444
11	qwen3.5-397b-a17b	Alibaba	1442
12	glm-4.7	Z.ai	1442
13	deepseek-v4-flash-thinking	DeepSeek	1439
14	gemma-4-26b-a4b	Google	1438
15	deepseek-v4-flash	DeepSeek	1436

開源 MoE LLM 排名 Top 30 (16-30)

開放權重(MIT/Apache 2.0/Modified MIT等)且架構為 Mixture-of-Experts

排名	模型	開發團隊	Arena分數
16	mimo-v2.5	Xiaomi	1433
17	kimi-k2.5-instant	Moonshot	1431
18	kimi-k2-thinking-turbo	Moonshot	1430
19	nvidia-nemotron-3-ultra-550b-a55b-nvfp4	Nvidia	1425
20	glm-4.6	Z.ai	1425
21	deepseek-v3.2	DeepSeek	1425
22	deepseek-v3.2-exp-thinking	DeepSeek	1425
23	qwen3-235b-a22b-instruct-2507	Alibaba	1423
24	deepseek-v3.2-thinking	DeepSeek	1423
25	deepseek-v3.2-exp	DeepSeek	1423
26	deepseek-r1-0528	DeepSeek	1422
27	kimi-k2-0905-preview	Moonshot	1418
28	deepseek-v3.1	DeepSeek	1417
29	kimi-k2-0711-preview	Moonshot	1417
30	qwen3.5-122b-a10b	Alibaba	1417

Apple M4 Max 本機部署可行性分級說明

分級依據實測/估算之量化後記憶體需求,而非僅依總參數區間粗略判斷

A

36GB就能跑,速度最快

啟用參數 $\leq 4B$ 且總參數小,例如
Gemma 4 26B-A4B、Qwen3-30B-A3B

B

48-64GB可跑,速度尚可

總參數約30-65B且啟用參數偏小,例如
Qwen3.6-35B-A3B、Qwen3-Coder-Next

C

128GB裝得下但很緊繃

實測量化記憶體需求約80-115GB,例如
Qwen3.5-122B-A10B

D

128GB也裝不下,只能用API

實測/估算量化需求超過128GB,例如
DeepSeek V4-Pro、Kimi K2.6、GLM-5系列

MoE LLM 搭配 Apple M4 Max 採用建議 (1-15)

沿用開源MoE Top30名單,分級依 willitrunai 實測或公式估算查證

排名	模型	分數	總參數/啟用參數	分級	備註
1	glm-5.1	1470	754B/40B	D	willitrunai實測Q4_K_M約482GB,遠超128GB上限,只能用API
2	glm-5.2 (max)	1469	753B/40B	D	willitrunai實測約459.5-481.6GB(依平衡設定不同)
3	mimo-v2.5-pro	1467	1.02T/42B	D	社群實測INT4約675GB
4	kimi-k2.6	1461	1T/32B	D	willitrunai實測Q4_K_M約620GB
5	glm-5	1457	744B/40B	D	willitrunai實測約475.9GB
6	deepseek-v4-pro	1457	1.6T/49B	D	社群估算Q4約800GB
7	deepseek-v4-pro-thinking	1455	1.6T/49B	D	與deepseek-v4-pro同底座,約800GB
8	kimi-k2.5-thinking	1450	1T/32B	D	同Kimi K2家族規模,約620GB
9	inkling	1445	975B/41B	D	今日新入榜(Thinking Machines Lab,Apache 2.0,2026-07-15首發);Unsloth動態GGUF Q4約270-317GB
10	minimax-m3	1444	428B/23B	D	社群GGUF實測Q4_K_M/XL約220-265GB;授權為MiniMax Community License(非純MIT/Apache,大型商用需另申請授權)
11	qwen3.5-397b-a17b	1442	397B/17B	D	willitrunai實測約242GB
12	glm-4.7	1442	357B/32B	D	同GLM-4.6/4.5規模量級,估算約215-220GB(估計,willitrunai無直接頁面)
13	deepseek-v4-flash-thinking	1439	284B/13B	C	與deepseek-v4-flash同底座,willitrunai實測約95GB,128GB內可跑但偏緊繃
14	gemma-4-26b-a4b	1438	25.2B/3.8B	A	willitrunai實測約20.8GB,啟用參數僅3.8B,36GB內即可流暢運行,今日Top30唯一A級
15	deepseek-v4-flash	1436	284B/13B	C	willitrunai實測Q4_K_M約95.16GB,128GB內可跑但偏緊繃;部分來源總參數標示158B,版本說法不一但Q4實測數字一致

MoE LLM 搭配 Apple M4 Max 採用建議 (16-30)

沿用開源MoE Top30名單,分級依 willitrunai 實測或公式估算查證

排名	模型	分數	總參數/啟用參數	分級	備註
16	mimo-v2.5	1433	310B/15B	D	HuggingFace GGUF實測Q4_K_M約191GB
17	kimi-k2.5-instant	1431	1T/32B	D	同Kimi K2家族,約620GB
18	kimi-k2-thinking-turbo	1430	1T/32B	D	同Kimi K2家族,約600-620GB
19	nvidia-nemotron-3-ultra-550b-a55b-nvfp4	1425	550B/55B	D	★常見誤解:模型名稱已標榜NVFP4原生4-bit格式,容易誤認「已經很小」,但55B啟用參數仍需完整550B專家權重常駐記憶體,官方數據約275GB,遠超128GB
20	glm-4.6	1425	355B/32B	D	估算約213-216GB(估計)
21	deepseek-v3.2	1425	685B/37B	D	與V3/R1同量級,估算Q4約404GB
22	deepseek-v3.2-exp-thinking	1425	685B/37B	D	同deepseek-v3.2底座,估算約404GB
23	qwen3-235b-a22b-instruct-2507	1423	235B/22B	D	★常見誤解:22B啟用參數常被誤認128GB機型裝得下,willitrunai實測Q4約132GB,僅略超128GB上限,實際仍裝不下
24	deepseek-v3.2-thinking	1423	685B/37B	D	估算約404GB
25	deepseek-v3.2-exp	1423	685B/37B	D	估算約404GB
26	deepseek-r1-0528	1422	671B/37B	D	社群實測Q4_K_M約404GB(常見量化基準值)
27	kimi-k2-0905-preview	1418	1T/32B	D	同Kimi K2家族,約620GB
28	deepseek-v3.1	1417	671B/37B	D	估算約404GB
29	kimi-k2-0711-preview	1417	1T/32B	D	同Kimi K2家族,約620GB
30	qwen3.5-122b-a10b	1417	122B/10B	C	willitrunai實測約74.4GB,128GB機型內尚餘約50GB可用於KV cache/長context,今日Top30品質優先候選之一

MacBook Air 16GB 地端 Agentic AI 部署評估

16GB統一記憶體扣掉macOS系統保留,實際可用約8-10GB;Agentic工作負載下KV cache會持續成長,權重建議壓在6-8GB內;MacBook Air無風扇,持續agent迴圈易熱降頻,啟用參數越小越有利

模型	開發團隊	總參數/啟用	Q4記憶體	判定	備註
LFM2.5-8B-A1B	Liquid AI	8.3B/1.5B	Q4_K_M約6GB(官方/willitrunai)	可跑	128K context,原生Pythonic tool calling+內建reasoning;授權為LFM Open License v1.0(年收入超過\$10M需另洽商業授權,非單純MIT/Apache)
Ling-mini-2.0	InclusionAI(Ant Group)	16B/1.4B	Q4_K_M約9.91GB(HuggingFace GGUF實測)	緊繃	今日spot-check新發現候選;MIT授權,支援tool/function calling與JSON輸出,131K context;啟用僅1.4B推理快,但緊繃區間不建議長時間agent迴圈
GPT-OSS-20B	OpenAI	21B/3.6B	Q4_K_M權重約12-12.8GB(來源略有分歧)	裝不下	Apache 2.0;原生支援function calling/瀏覽/程式執行;即使取估計區間下緣仍超過16GB Air的11GB門檻
ERNIE-4.5-21B-A3B	Baidu	21B/3B	Q4_K_M約13.2GB(HuggingFace GGUF實測)	裝不下	Apache 2.0;原生支援function calling,128K context
Qwen3-30B-A3B-Instruct-2507	Alibaba	30.5B/3.3B	Q4_K_M約18.6GB(HuggingFace GGUF實測)	裝不下	Apache 2.0;Qwen-Agent工具呼叫生態成熟
Qwen3.5-35B-A3B	Alibaba	35B/3B	Q4_K_M約21.4GB(willitrunai實測)	裝不下	Apache 2.0
Gemma-4-26B-A4B	Google	25.2B/3.8B	標準Q4_K_M約14.4-16.8GB;QAT 4-bit checkpoint可壓到約15GB以下	裝不下	Apache 2.0;QAT版本比標準量化省幾GB,但仍超過16GB Air約11GB的agentic預算上限

Agentic MoE 首選

LFM2.5-8B-A1B

8.3B/1.5B / Q4_K_M約6GB

16GB Air上唯一從容可跑的MoE候選,剩約3-4GB可留給KV cache;128K context、原生tool calling、內建reasoning,無風扇Air上速度快、發熱低。今日spot-check新發現Ling-mini-2.0(16B/1.4B,MIT)為緊繃區備選,但LFM2.5授權條款更成熟,仍是agentic長迴圈首選

Dense 替代方案

Qwen3.5-9B

9B dense / Q4_K_M約5.5-7GB

Apache 2.0;不堅持MoE架構時品質上限更高,MMLU-Pro/GPQA等基準優於多款更大模型,適合單次重推理任務

結論與建議

依當日 Arena 排名與 M4 Max 128GB 部署查證結果

日常本機首選

gemma-4-26b-a4b

Arena分數 1438 / 分級 A

連續第二日蟬聯Top30開源MoE中唯一A級模型,willitrunai實測僅需約20.8GB,速度快、隨開即用,為M4 Max日常本機首選(16GB Air仍裝不下,詳見air16_eval)

品質優先(128GB機型)

deepseek-v4-flash-thinking

Arena分數 1439 / 分級 C

Q4_K_M僅需約95GB即可在128GB機型上運行,是今日Top30中分數最高且能落在128GB內(含C級)的模型,分數較昨日(1438)微升1分

旗艦模型現況

Top30中有 26/30 款為 D級(裝不下)

Arena分數 / 分級

Qwen3-235B-A22B-Instruct-2507:常被誤認22B啟用參數應該裝得下,willitrunai實測Q4約132GB,僅略超128GB上限,實際仍裝不下

NVIDIA Nemotron-3-Ultra-550B-A55B-NVFP4:模型名稱已標榜NVFP4原生4-bit格式,容易被誤認「已經是量化版所以應該很小」,但55B啟用參數仍需完整550B專家權重常駐記憶體,官方數據約275GB,遠超128GB

DeepSeek V4 Flash / V4 Flash-Thinking(反向案例):284B總參數表面上容易被誤判為裝不下,但因架構效率高,willitrunai實測Q4_K_M僅需約95GB,是Top30中少數能在128GB內運行(C級)的機型,說明不能只看總參數規模判斷

與前一日報告比較: 與7/21相比,Arena總投票數由7,399,550增至7,430,560(+31,010票),總上架模型數378持平。開源MoE榜首仍為glm-5.1(1470,持平),glm-5.2(max)微降至1469(-1分);mimo-v2.5-pro維持在前段班(1467,+1);kimi-k2.6持平於1461。今日新入榜兩款值得留意:Thinking Machines Lab首款開放權重模型inkling(975B/41B,Apache 2.0,第9名)、NVIDIA Nemotron-3-Ultra-550B-A55B-NVFP4(第19名)。日常本機首選(A級)連續兩日皆為gemma-4-26b-a4b(1438,持平);品質優先選擇同為deepseek-v4-flash-thinking,分數由1438微升至1439。旗艦裝不下比例維持26/30,與昨日相同,顯示128GB機型仍難以承載多數旗艦開源MoE的整體格局並未改變。